

AI 芯片 – GPU 详解

NVSwitch 基础



ZOMI



NVIDIA®

Talk Overview

I. 硬件基础

- GPU 工作原理
- GPU AI 编程本质

2. 英伟达 GPU 架构

- GPU 基础概念
- 从 Fermi 到 Volta 架构
- Turing 到 Hopper 架构

• **Tensor Code 和 NVLink 详解**

3. GPU 图形处理

- GPU 逻辑模块划分
- 算法到 GPU 硬件
- GPU 的软件栈
- 图形流水线基础
- 流水线不可编译单元
- 光线跟踪流水线

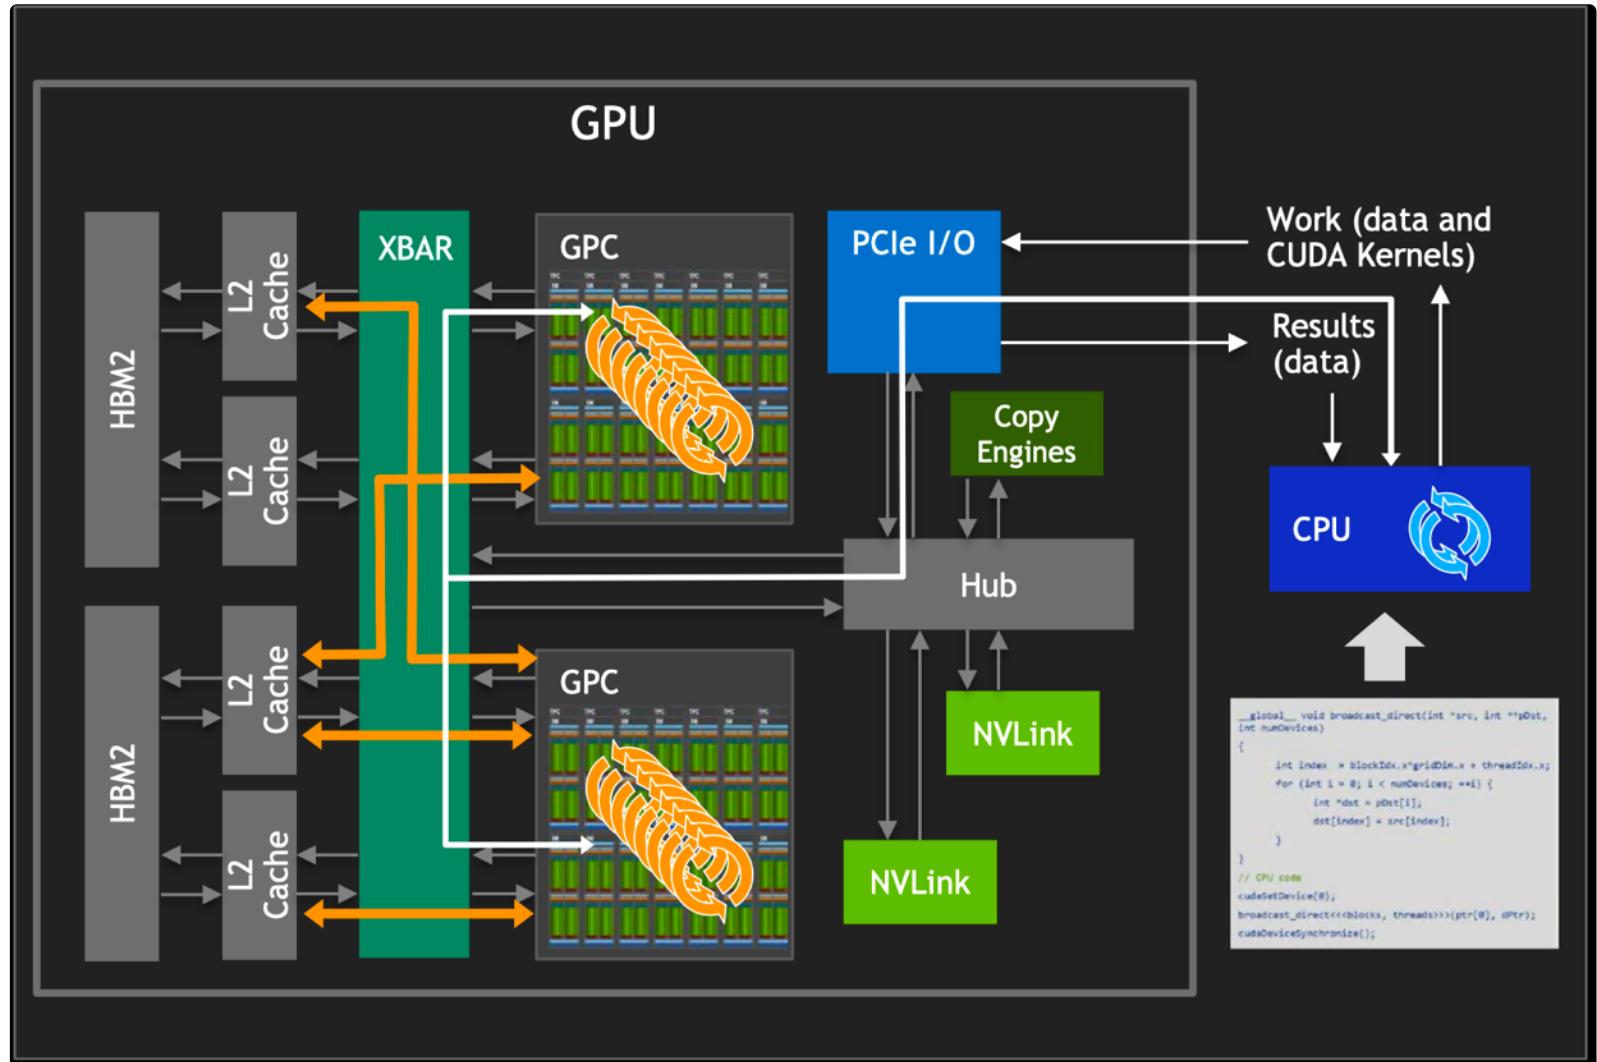
Talk Overview

I. 基本内容

- Appearance – NVSwitch 出现
- Details – NVSwitch 详解
- DGX – DGX 服务器介绍

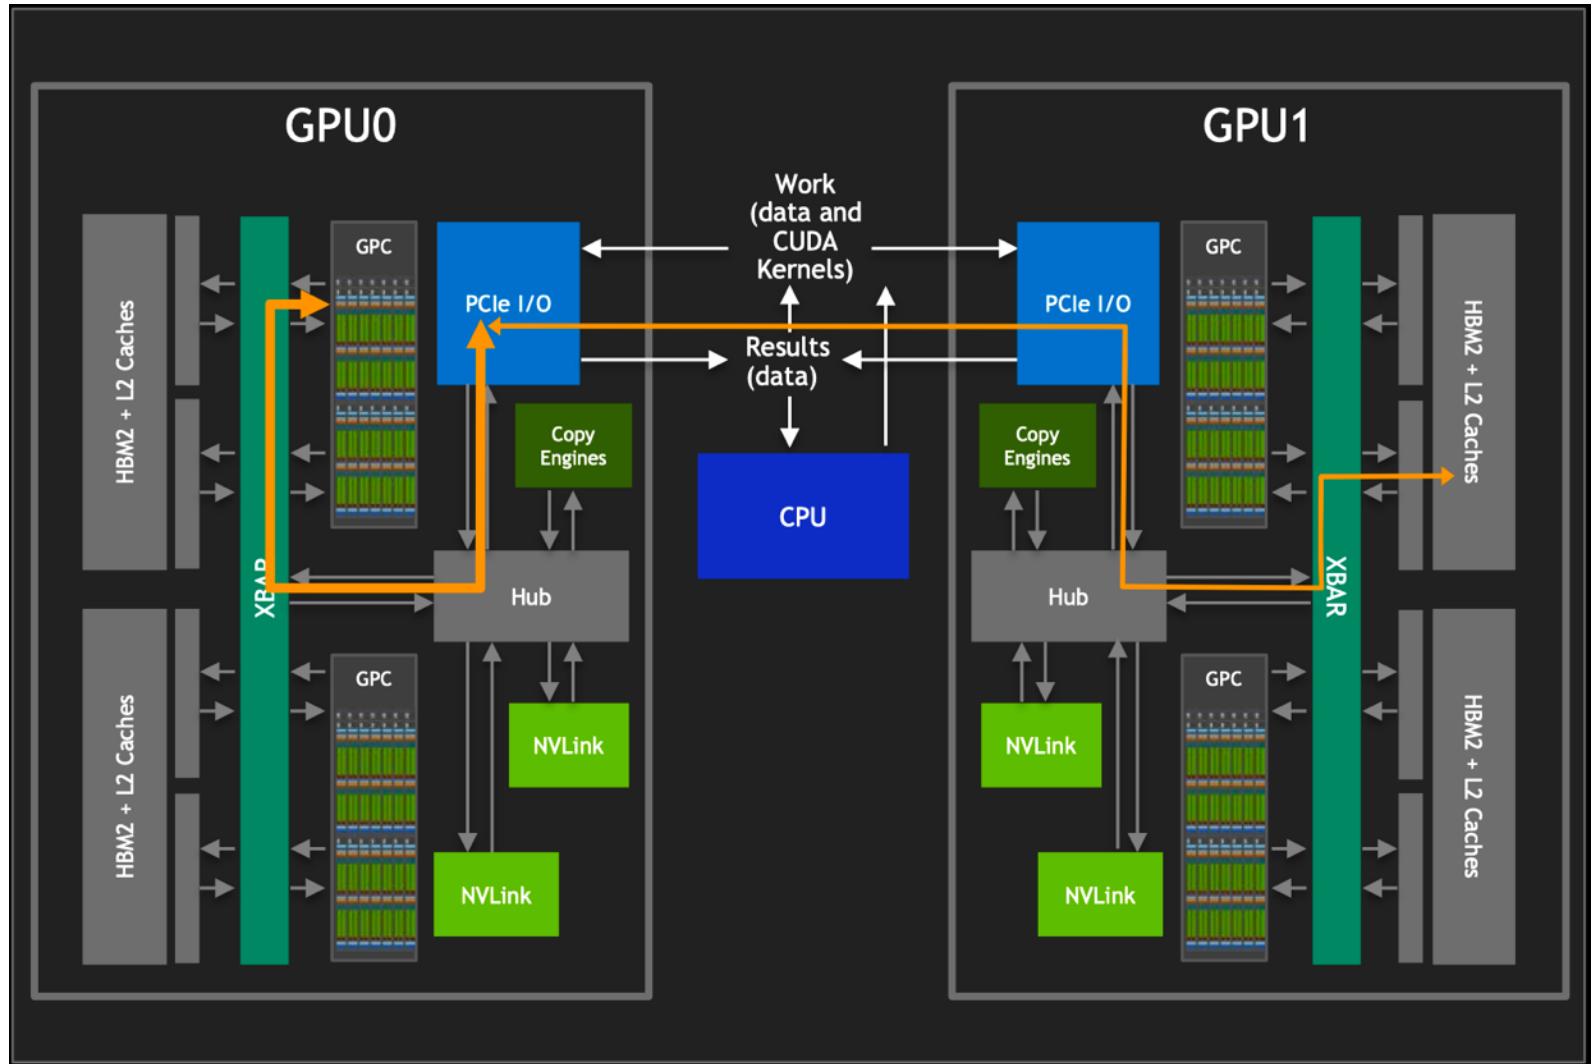
单 GPU 里面多个 SM 核心

- 使用 CUDA 来驱动硬件并行执行真正的计算；
- GPU 把线程工作分配给每个 GPC/SM cores；
- GPC/SM cores 利用 HBM2 中的数据进行计算；
- GPC/SM cores 之间可以共享 HBM2 中的数据；



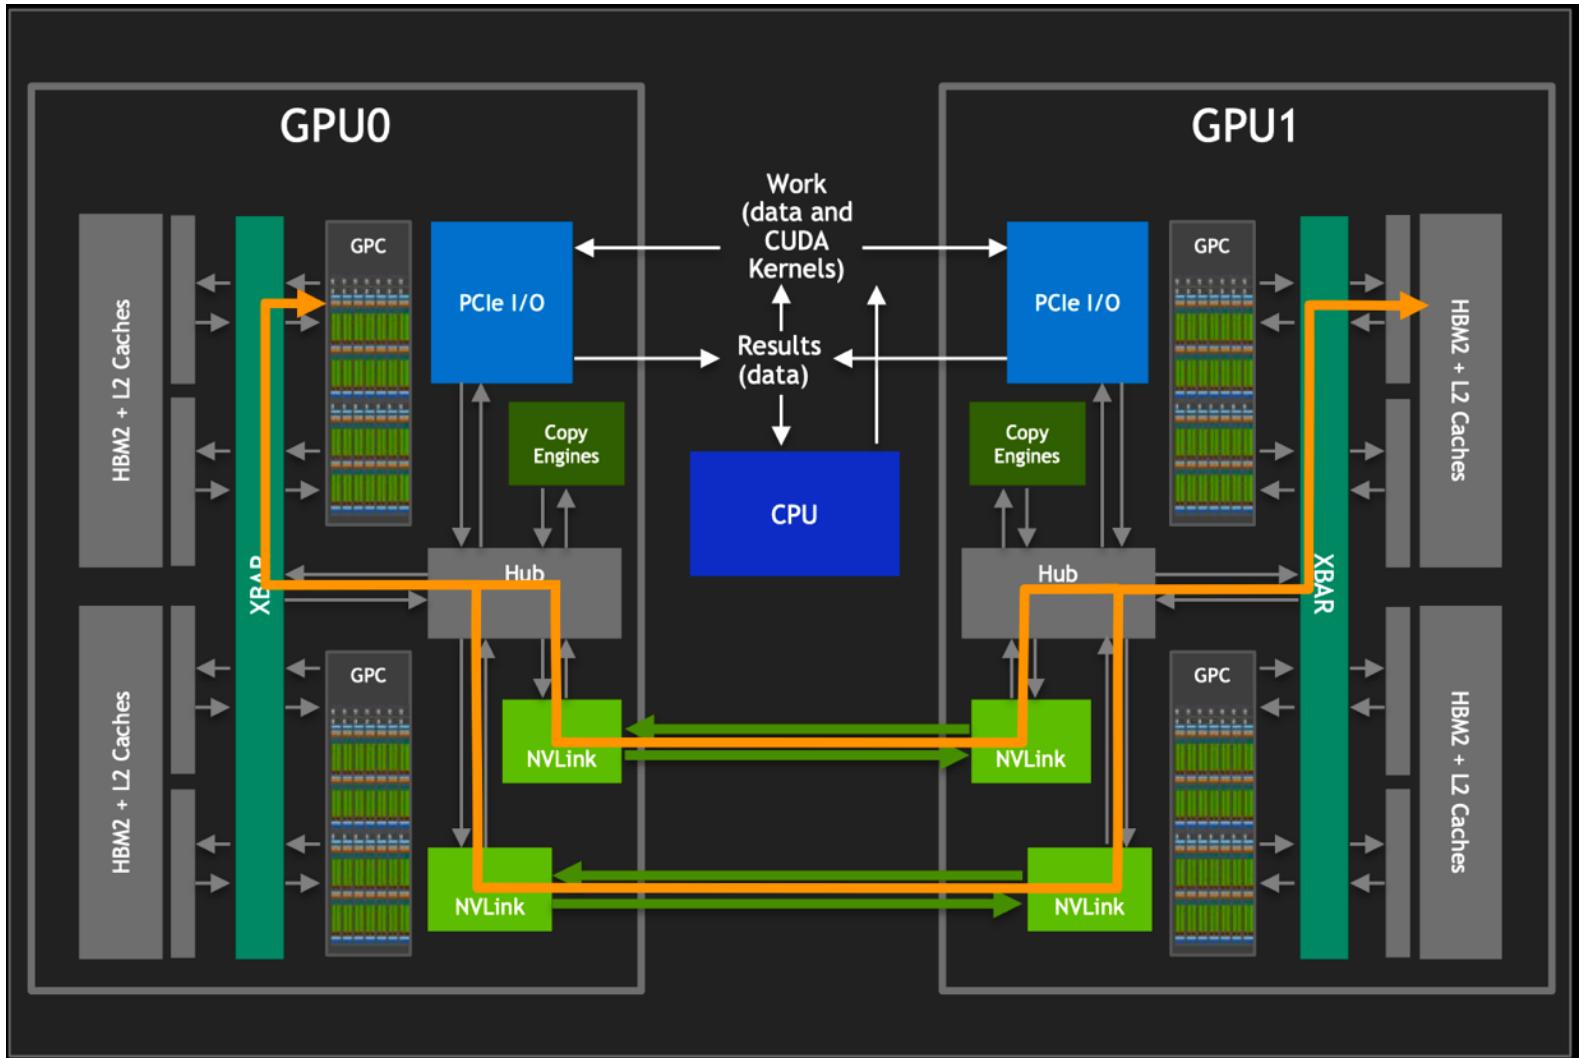
GPU 间通过 PCIe 通信

- 如果要对其他 GPU 的 HBM2 进行访问，需要走 PCIe；
- GPU-to-GPU 之间的交互需要通过 CPU 进行分配调度；
- PCIe 的带宽限制了 GPU-to-GPU 的速率；



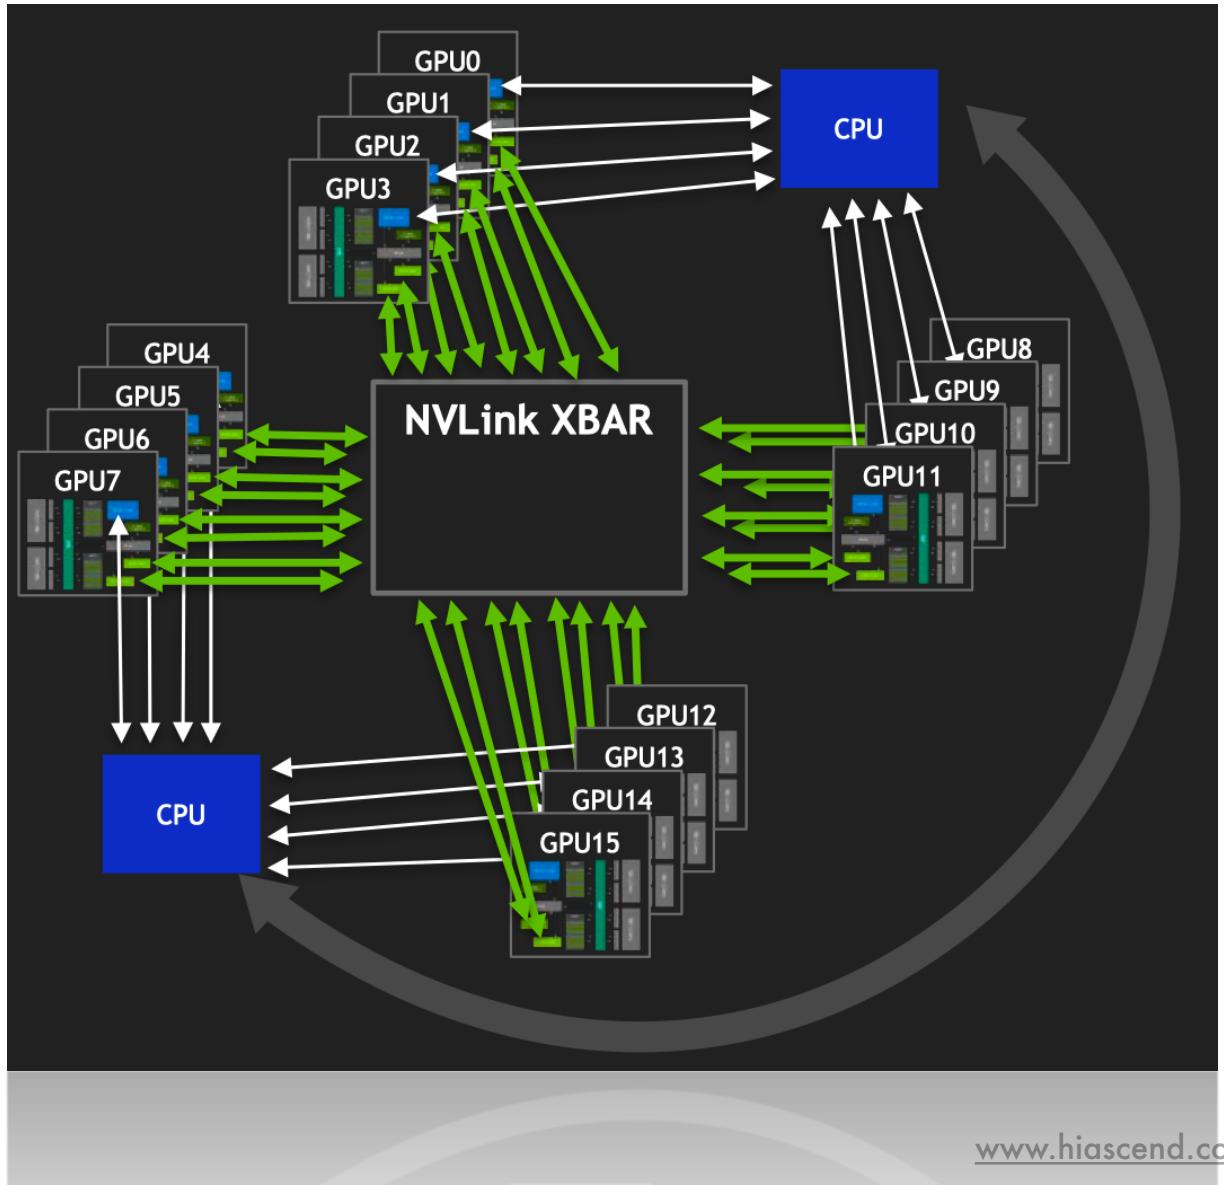
GPU 间使用 NVLink

- GPCs 可以访问卡间 HBM2 内存数据；
- 通过多条 NVLink 来对其他 GPU 内的 HBM2 数据进行访问；
- 成为了 XBARs 的桥梁，并且与 PCIe 不冲突，作为互补方案；

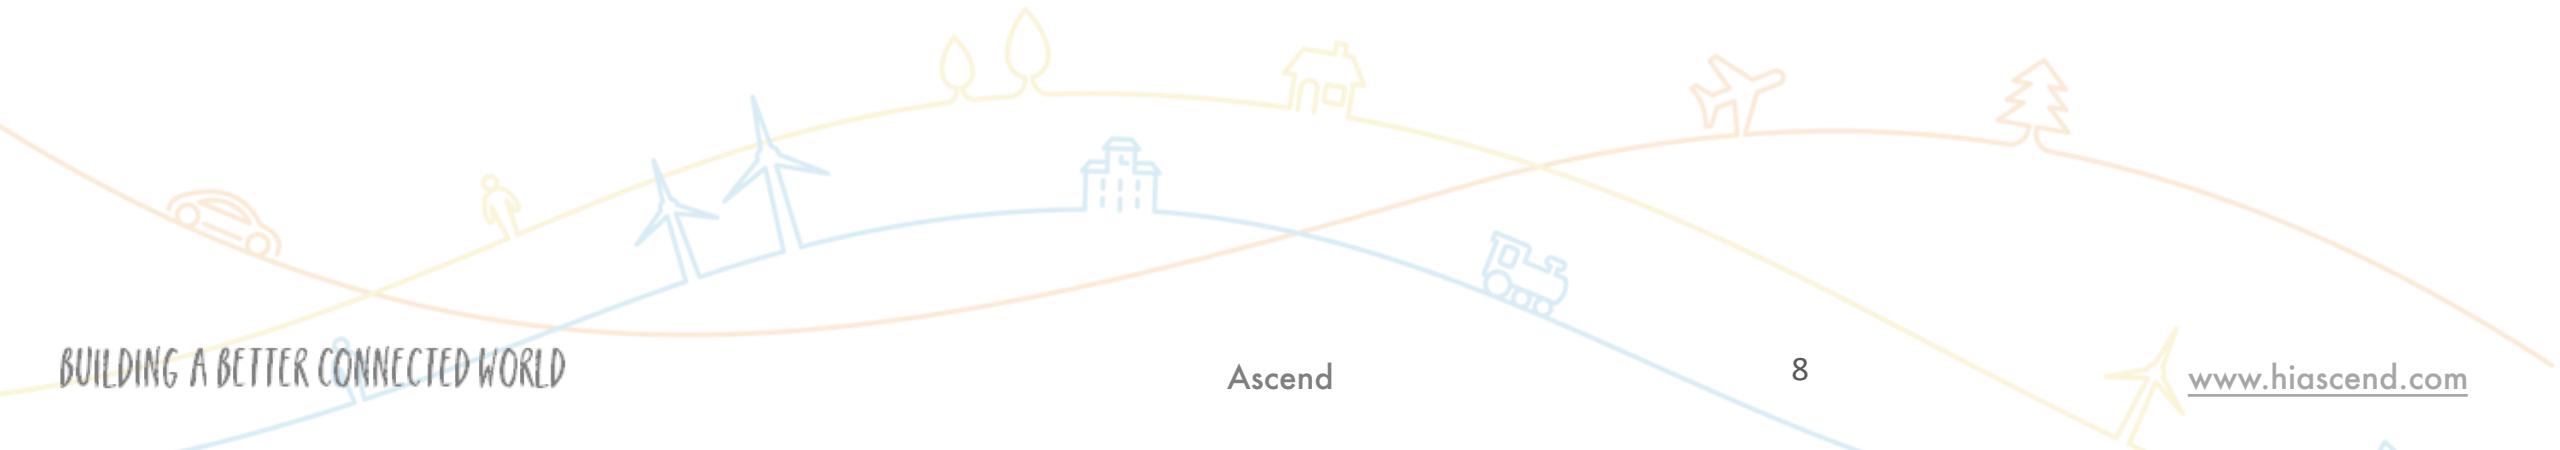


GPU 间互联

- NVLink 可以使得更多的GPU间进行互联；
- 实现单个 GPU 驱动进程可以控制所有 GPU的计算任务；
- HBM2 可以在不受其他进程干扰下下访问（LD/ST指令、 RDMA）；
- XBAR 作为桥接器可以独立演进发展，提供更高的带宽；



NVSwitch的出現



BUILDING A BETTER CONNECTED WORLD

Ascend

8

 www.hiascend.com

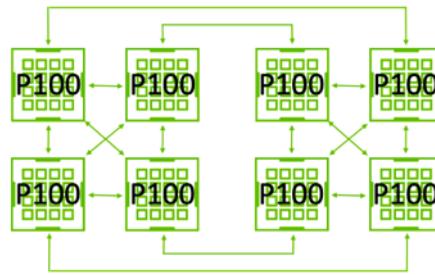
NVLink 发展

	First Generation	Second Generation	Third Generation	Fourth Generation
NVLink bandwidth per GPU	160GB/s	300GB/s	600GB/s	900GB/s
Maximum Number of Links per GPU	4	6	12	18
Supported NVIDIA Architectures	NVIDIA Pascal architecture	NVIDIA Volta architecture	NVIDIA Ampere Architecture	NVIDIA Hopper Architecture

NVSwitch发展

	First Generation	Second Generation	Third Generation
Number of GPUs with direct connection / node	Up to 8	Up to 8	Up to 8
NVSwitch GPU-to-GPU bandwidth	300GB/s	600GB/s	900GB/s
Total aggregate bandwidth	2.4TB/s	4.8TB/s	7.2TB/s
Supported NVIDIA architectures	NVIDIA Volta architecture	NVIDIA Ampere architecture	NVIDIA Hopper architecture

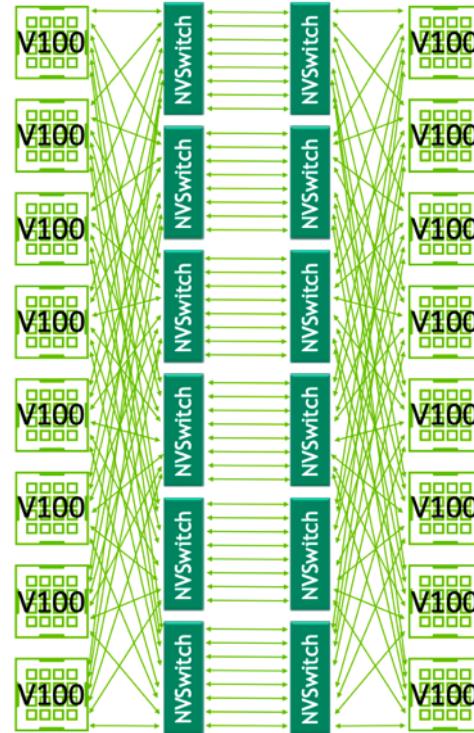
NVLink 与 NVSwitch 相关的服务器



2016

DGX-1 (P100)

140GB/s Bisection BW
40GB/s AllReduce BW



2018

DGX-2 (V100)

2.4TB/s Bisection BW
75GB/s AllReduce BW



2020

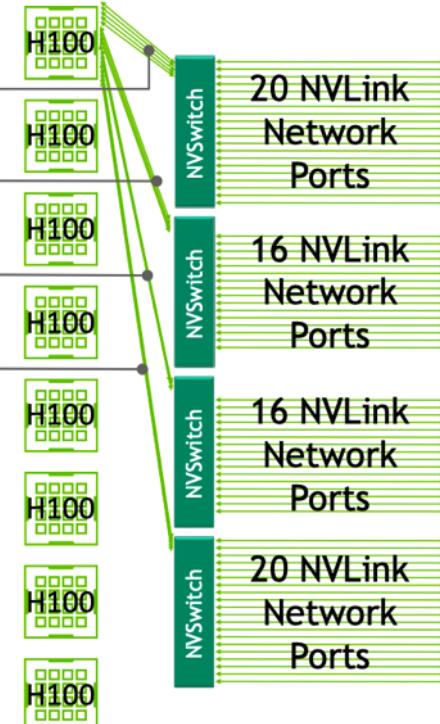
DGX A100

2.4TB/s Bisection BW
150GB/s AllReduce BW

2022

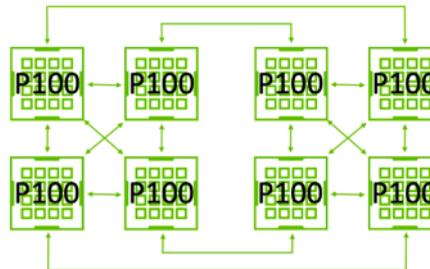
DGX H100

3.6TB/s Bisection BW
450GB/s AllReduce BW



NVLink 与 NVSwitch 相关的服务器

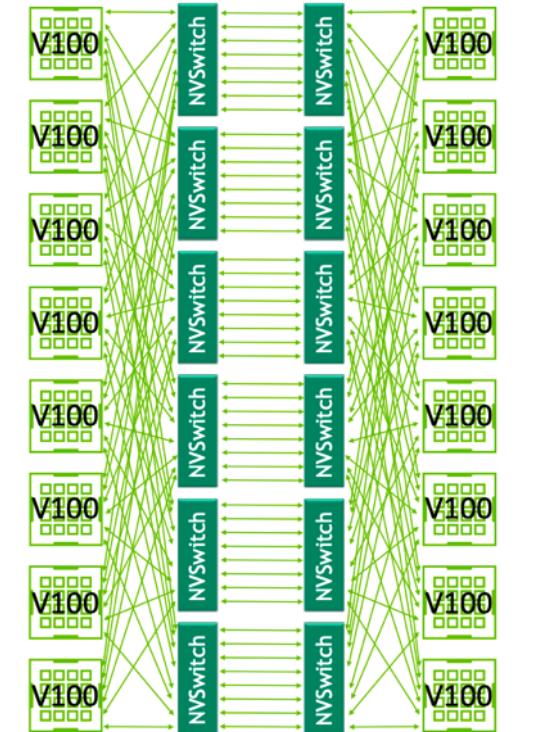
- NVLink 2.0 技术使得单服务器中 8 个 GPU 无法达到全连接为解决该问题，NVIDIA 在 2018 年发布了 NVSwitch，实现了 NVLink 的全连接。
- NVIDIA NVSwitch 是首款节点交换架构，可支持单个服务器节点中 16 个全互联的 GPU，并可使全部 8 个 GPU 对分别达到 300GB/s 的速度同时进行通信。



2016

DGX-1 (P100)

140GB/s Bisection BW
40GB/s AllReduce BW

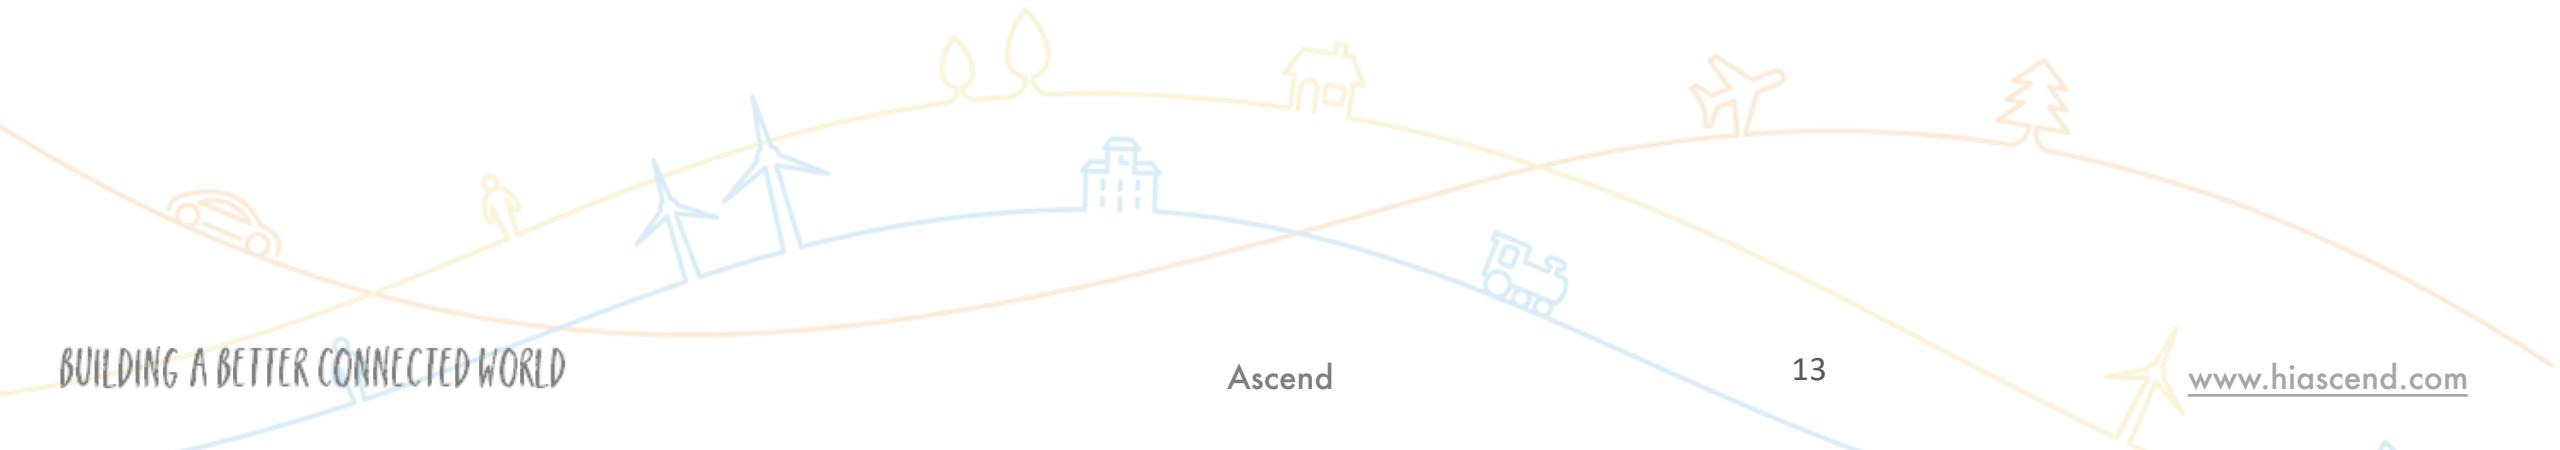


2018

DGX-2 (V100)

2.4TB/s Bisection BW
75GB/s AllReduce BW

NVSwitch详解



BUILDING A BETTER CONNECTED WORLD

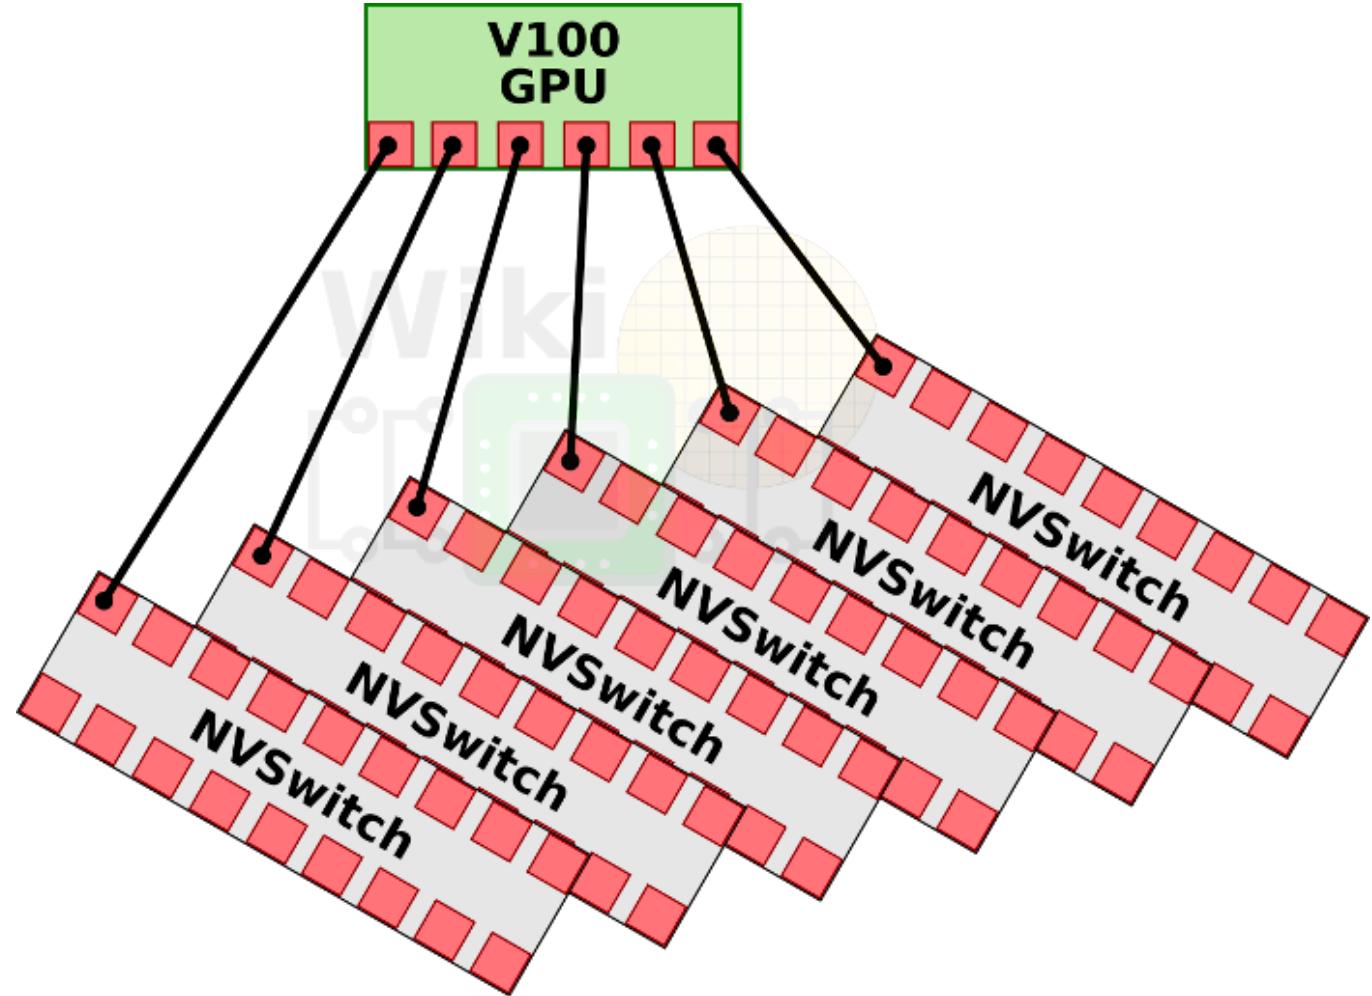
Ascend

13

 www.hiascend.com

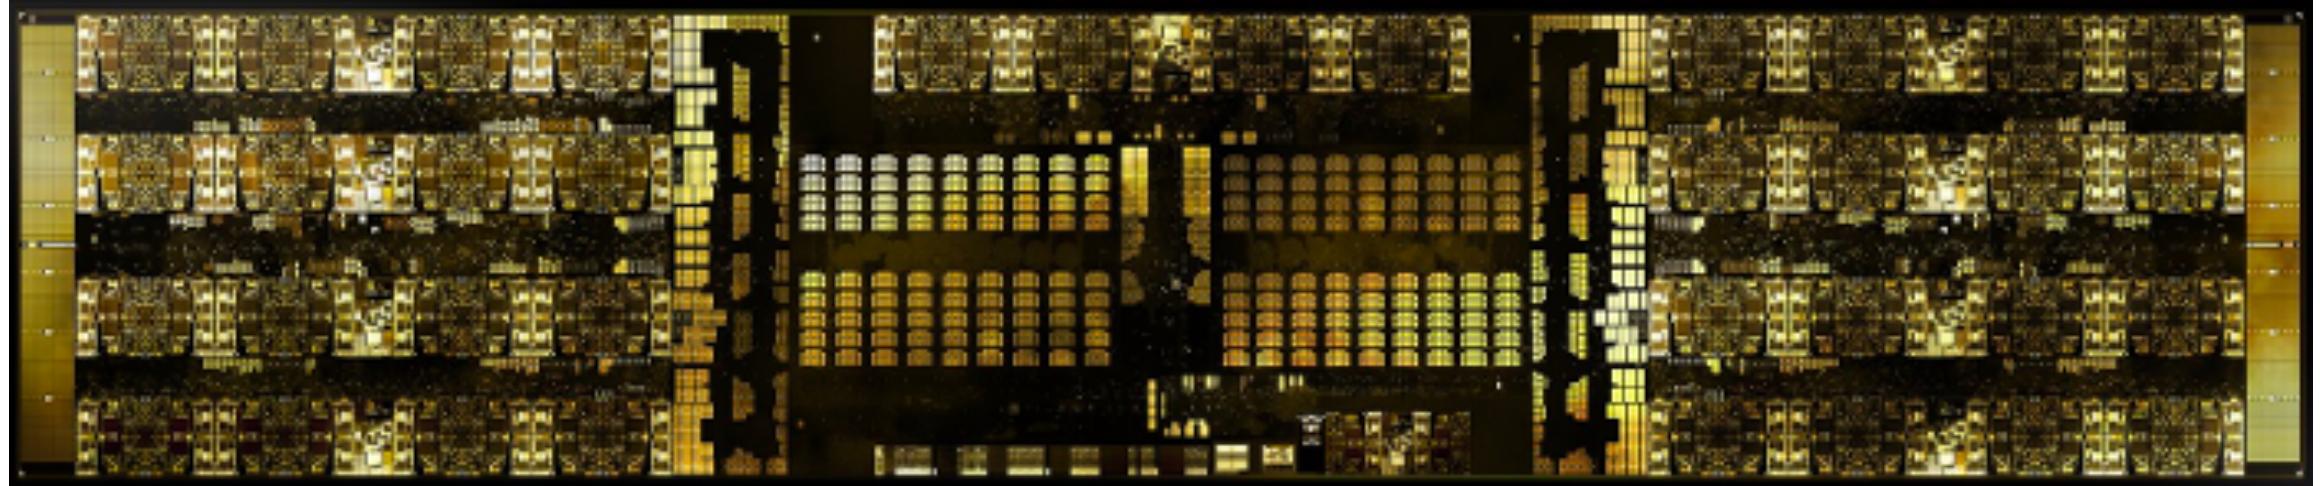
第一代 NVSwitch

- 通过 NVSwitch 提供的18路接口， NVSwitch 能够让 nvidia设计出完全无阻塞的全互联16路GPU系统。
- 每块v100中的6路 NVLink 将分别连接到6块 NVSwitch 上面。这样8块v100与6块 NVSwitch 完全连接，构成一个基板。



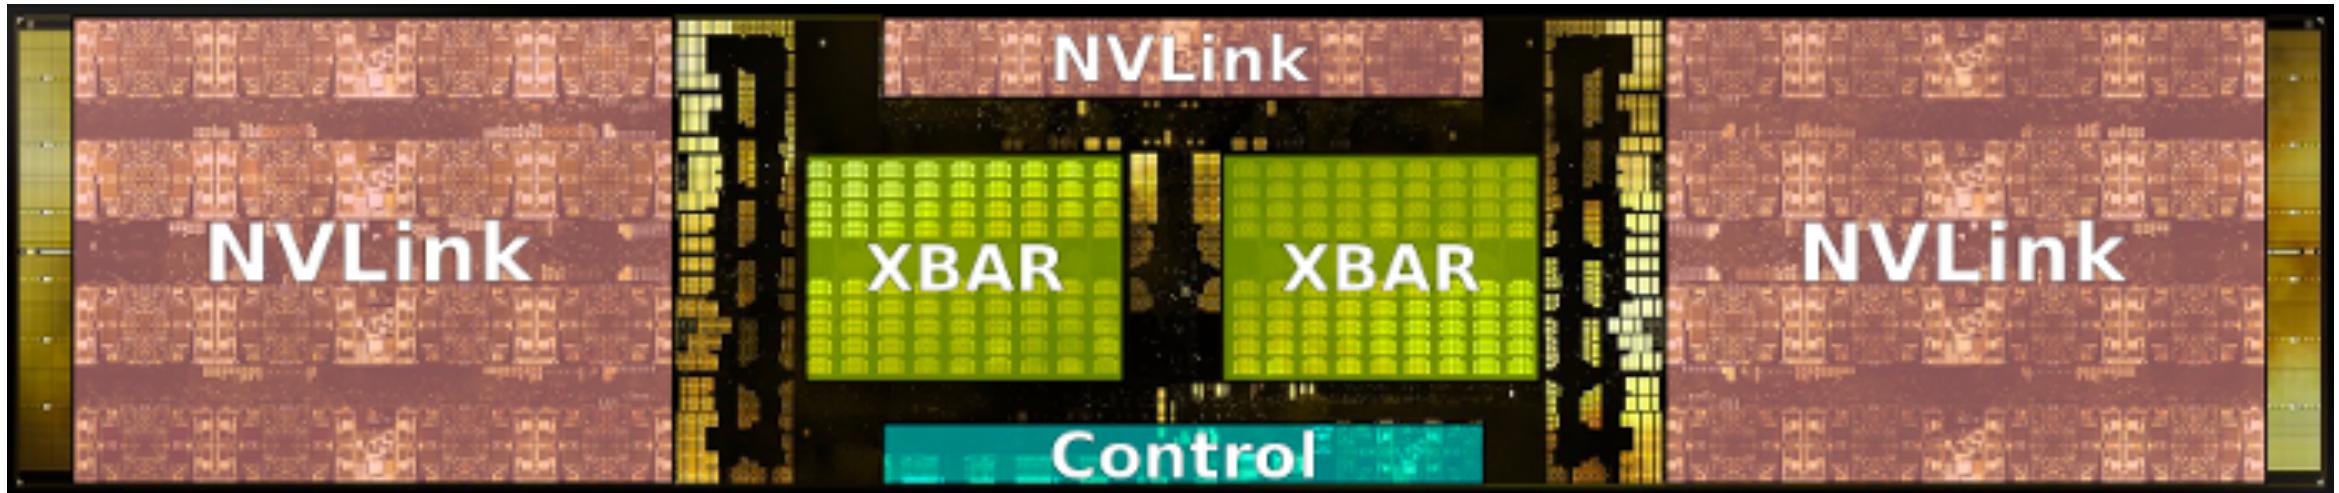
第一代 NVSwitch

- NVSwitch 是一块独立的 NVLink 芯片，其提供了高达18路 NVLink 的接口。支持 NVLink 2.0，每个接口均能提供双信道高达50GB/s 带宽，总计能够提供900GB/s的带宽。功率100w，基于台积电12nm FinFet FFN 工艺，拥有2b个晶体管。

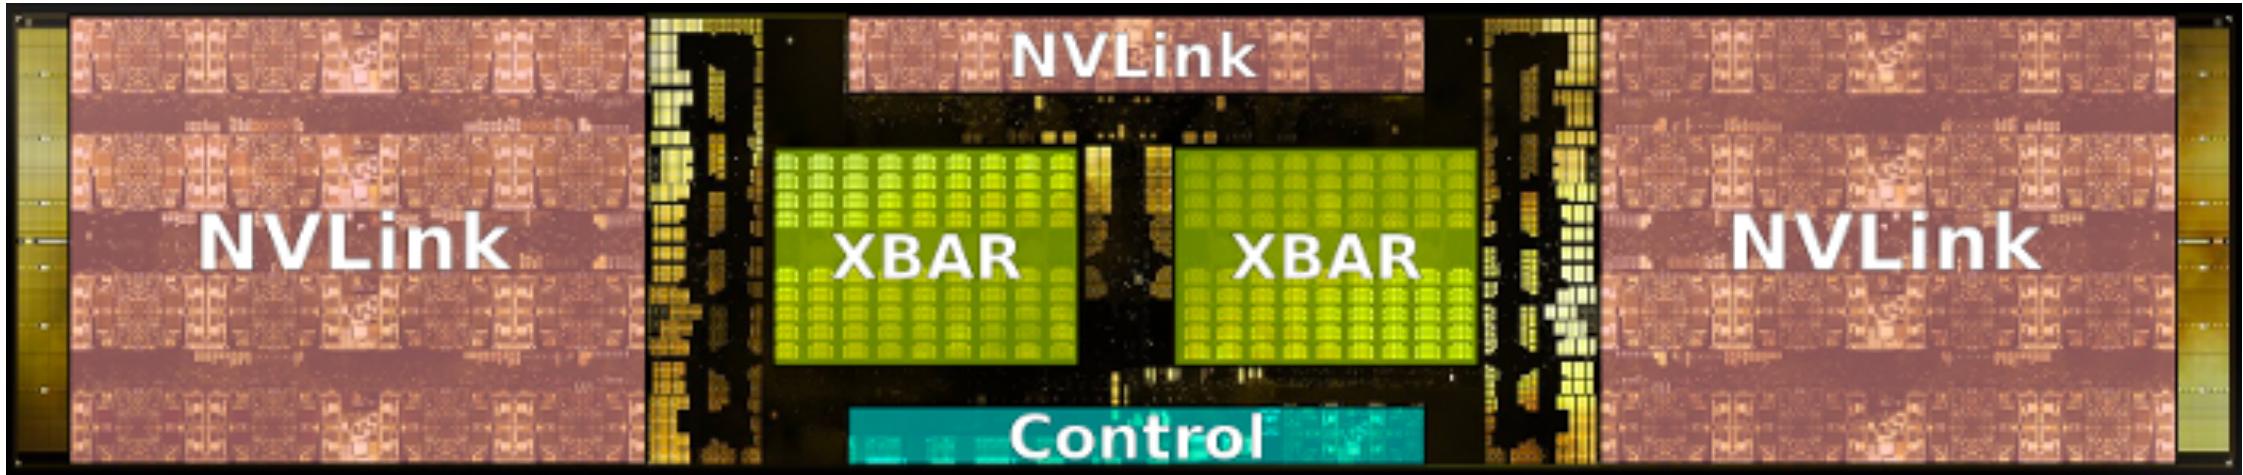


第一代 NVSwitch

- NVSwitch 封装在1940 个 pin 大小为 4cm² 的 BGA芯片中，其中 576 个针脚专门服务于 18 路的 NVLink，剩下的针脚用于电源和 I/O 接口，如管理端口x4 pcie、I2c、GPIO等。



NVLink2 NVSwitch1 特点



Parameter	Spec
每NVLink双向带宽	51.5 GBps
NRZ Lane Rate (x8 per NVLink)	25.78125 Gbps
Transistors	2 Billion
Process	TSMC 12FFN
Die Size	106 mm ²

Parameter	Spec
Bidirectional Aggregate Bandwidth	928 GBps
NVLink Ports	25.78125 Gbps
Mgmt Port (config, maintenance, errors)	PCIe
LD/ST BW Efficiency (128B pkts)	80.0%
Copy Engine BW Efficiency (256B pkts)	88.9%

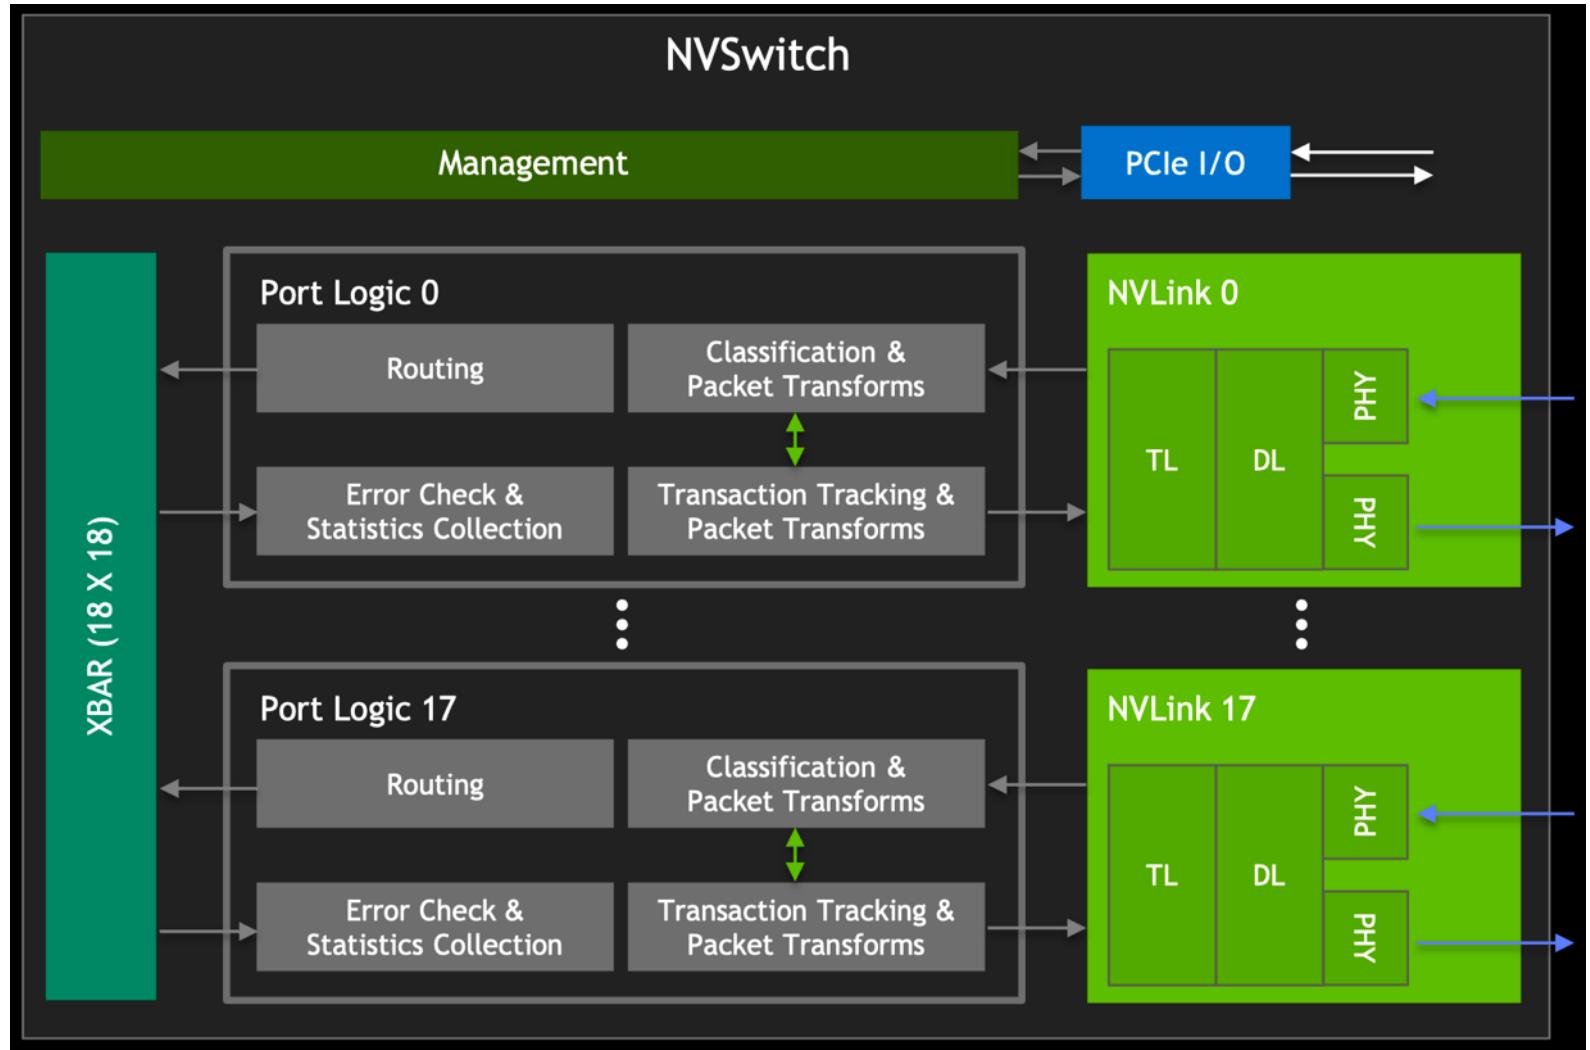
NVSwitch : DIE 电路



- **电路设计紧凑**：在电路上数据包的处理和交换（XBAR）逻辑非常紧凑
- **提升I/O面积**：I/O块占据了50%以上的面积，最大限度地提高物理链接电路的面积比
- **简化封装衬底布线**：所有NVLink端口在电路上都是并行的

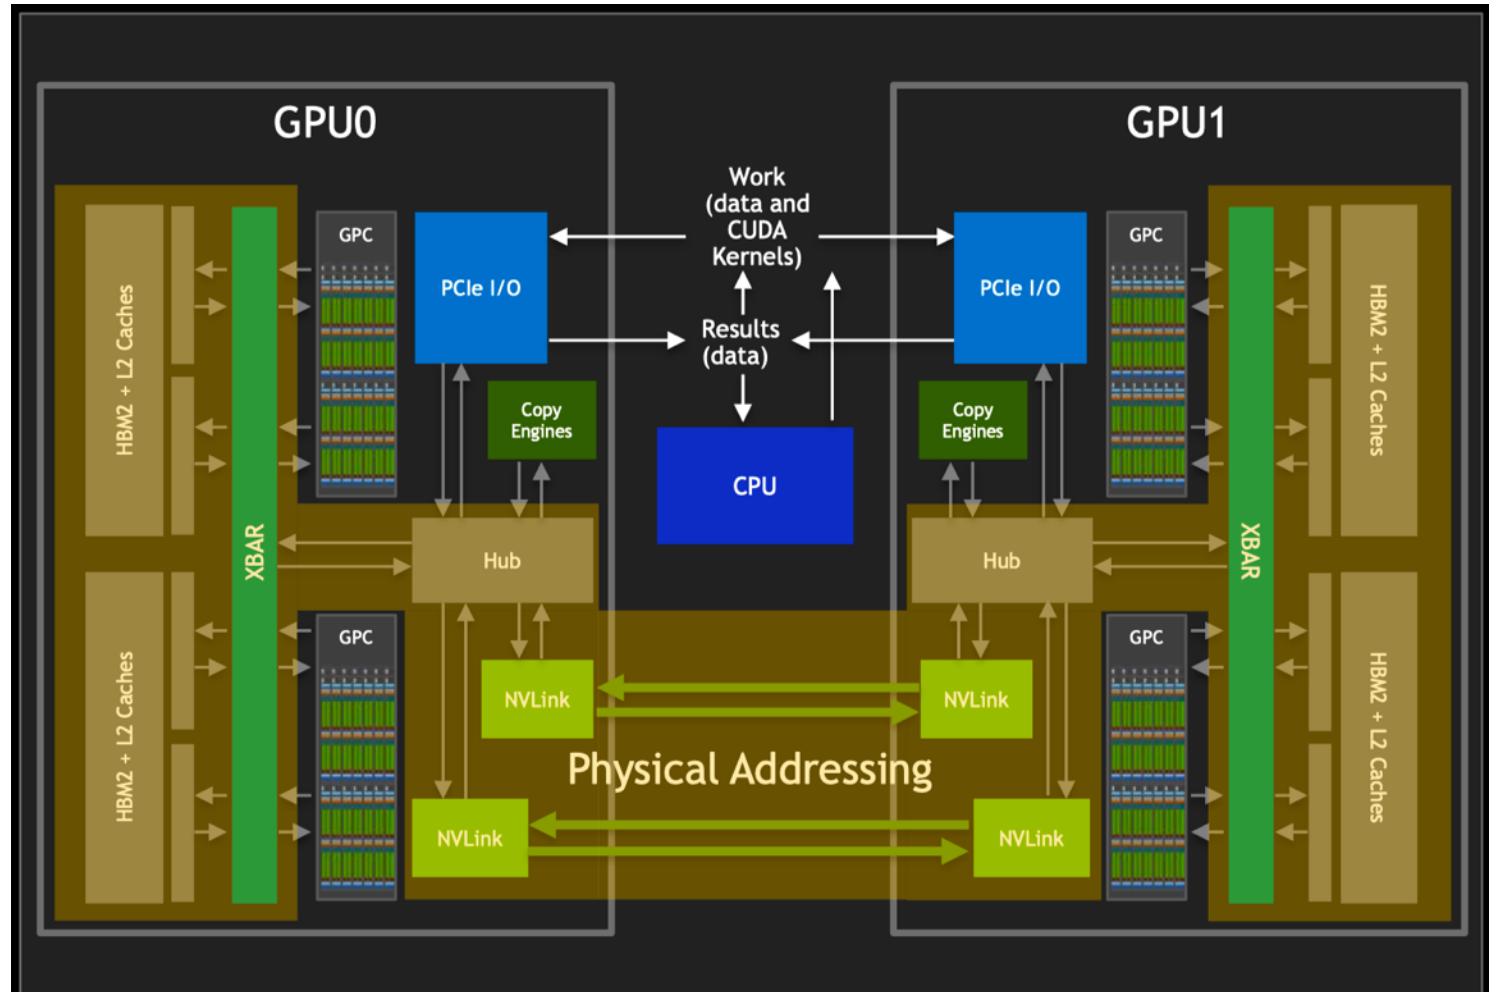
第一代 NVSwitch Block

1. GPU XBAR作为NVLink的桥接设备，非一般网络设备；
2. 数据包在多个GPU上流动/交换，客户面感知单个GPU；
3. 基于 SRAM 缓冲，XBAR 非阻塞；
4. 从V100重新使用NVLink I P块和XBAR设计/验证能力；



NVSwitch : 物理共享内存

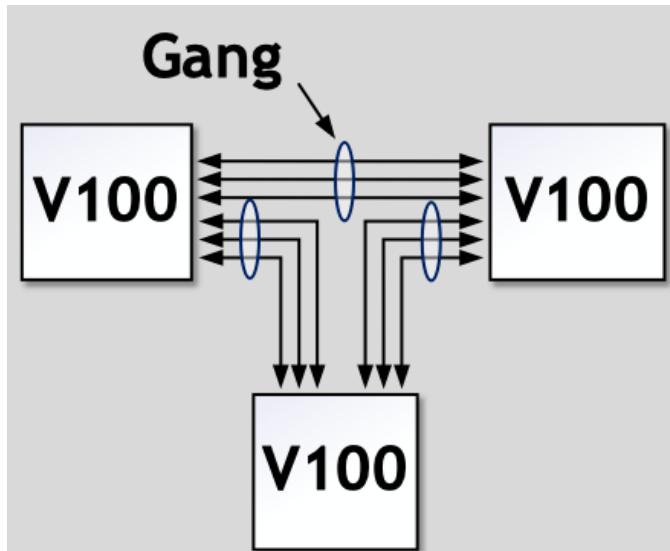
- 虚拟到物理地址转换GPC完成
- 物理地址在NVLink数据包中传输



简化互联交换方式

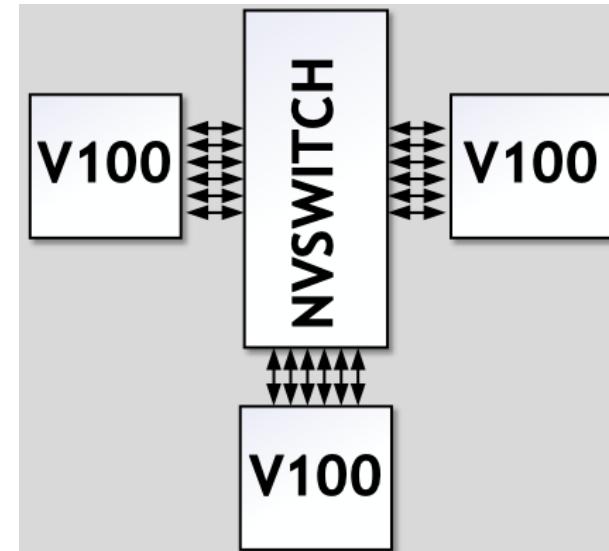
Without NVSwitch

- GPU 间直接连接
- 将NVLinks聚合为多个组 Gang
- GPU-GPU 间最大带宽受限于 Gang



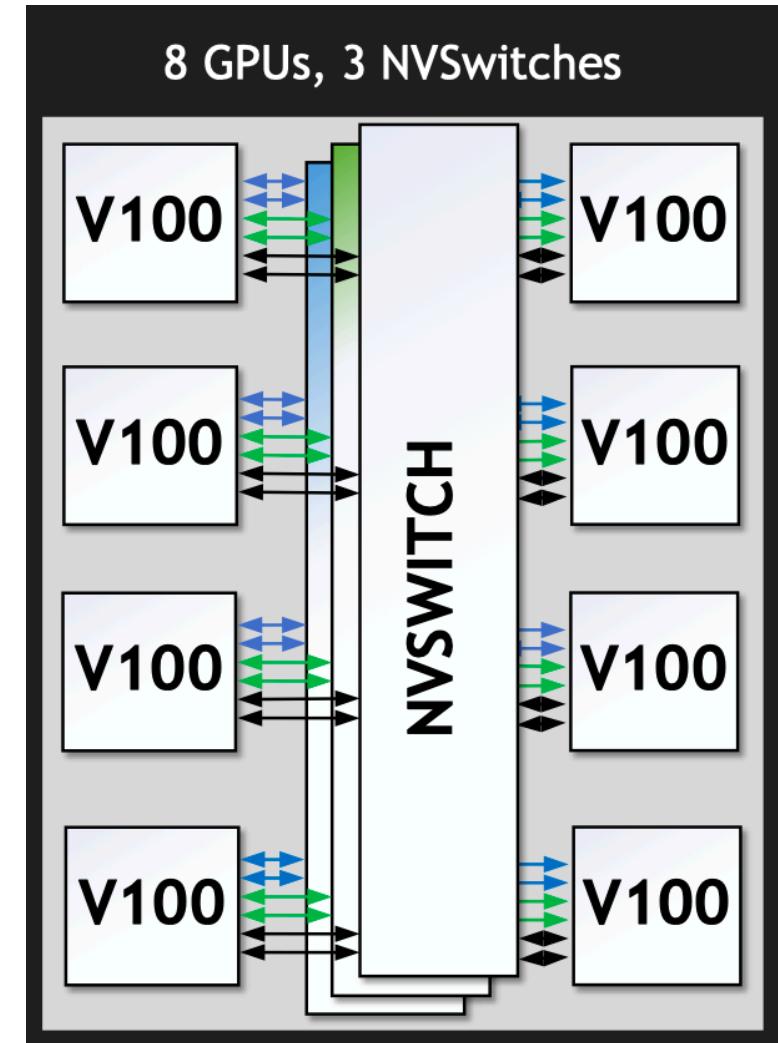
With NVSwitch

- 所有链路上数据可交互，任何一对GPU互联
- 只要不超过六个NVLink的总带宽，单GPU流量非阻塞

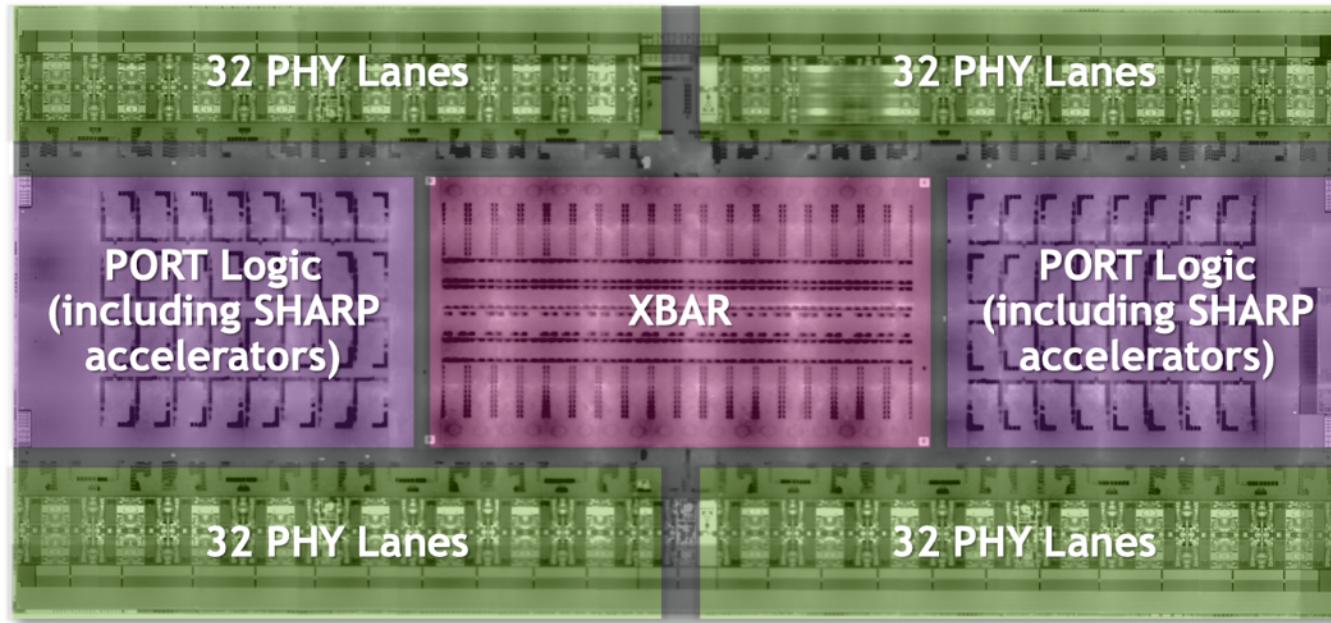


提供多个GPU间互联系统

1. 可以添加更多NVSwitch来支持更多GPU
2. 八个GPU可以用三个NVSwitch构建
3. 数据可以在所有GPU链路上交互
4. 任何一对GPU可以使用完整300GBps双向带宽通信
5. NVSwitch XBAR提供从A-B点唯一路径，实现通信无阻塞、无干扰



NVLink4 NVSwitch3 特点



最大 NVSwitch 模块

- TSMC 4N process
- 25.1B transistors
- 294mm²
- 50mmX50mm package (2645 balls)

最高的带宽

- 64 NVLink4 ports (x2 per NVLink)
- 3.2TB/s full-duplex bandwidth
- 50Gbaud PAM4 diff-pair signaling
- All ports NVLink Network capable

新能力

- 400GFLOPS of FP32 SHARP
- NVLink Network management, Security and telemetry engines

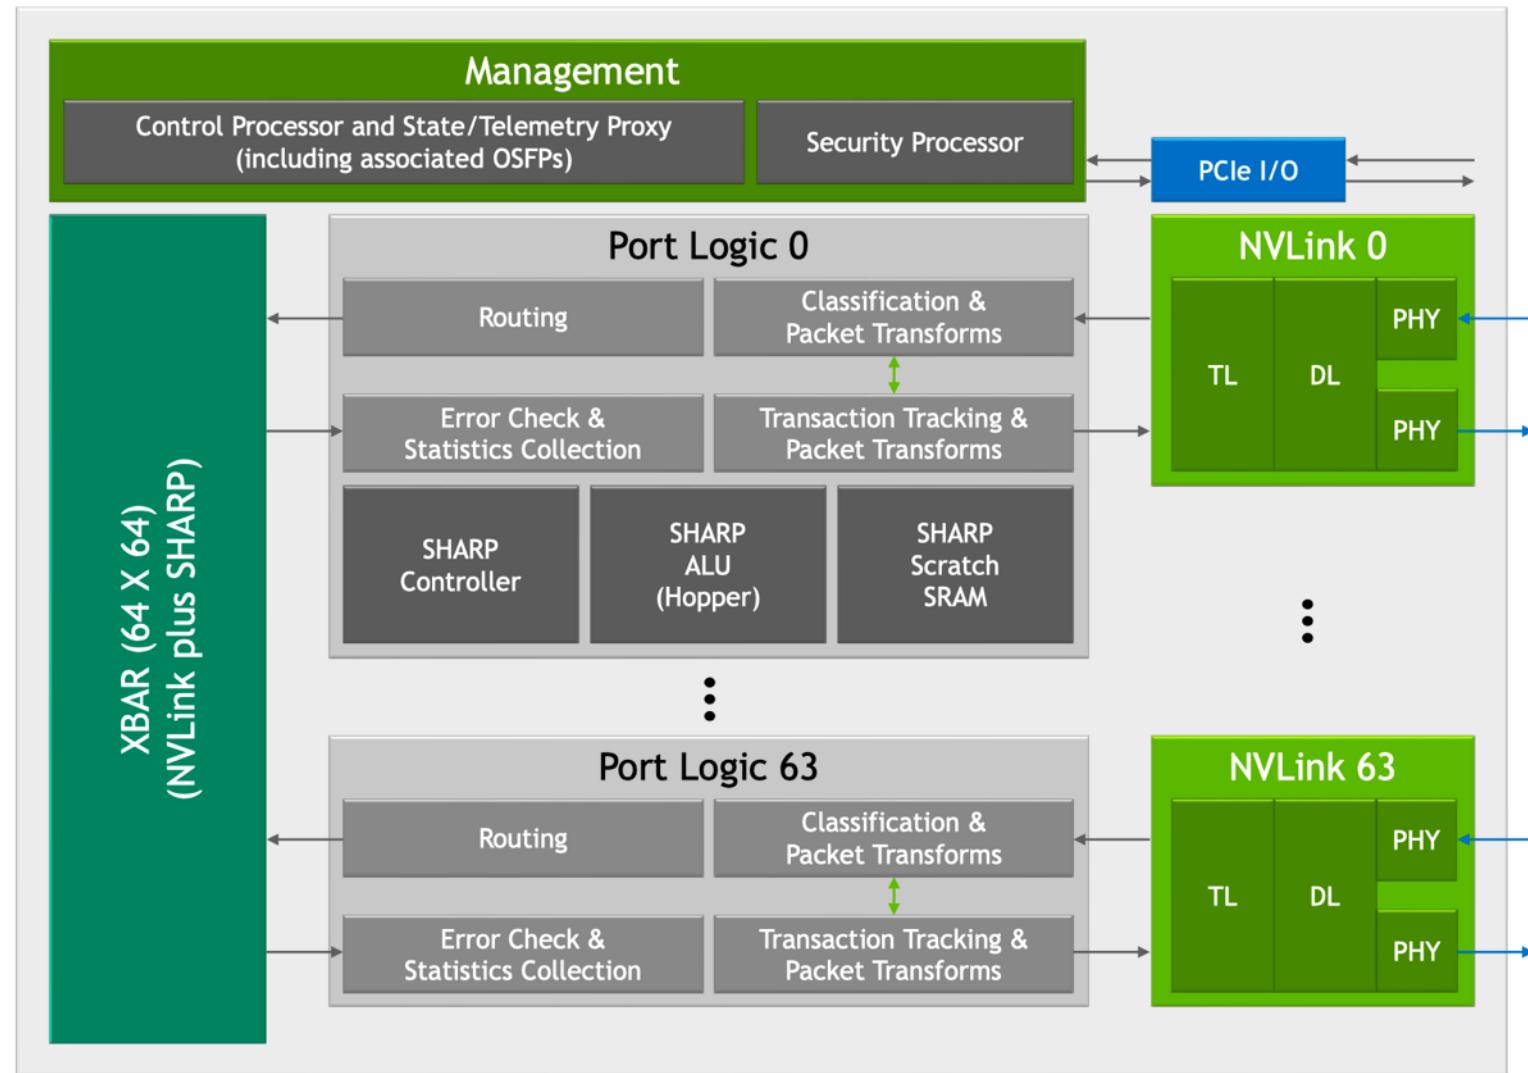
第三代 NVSwitch Block

新SHARP模块

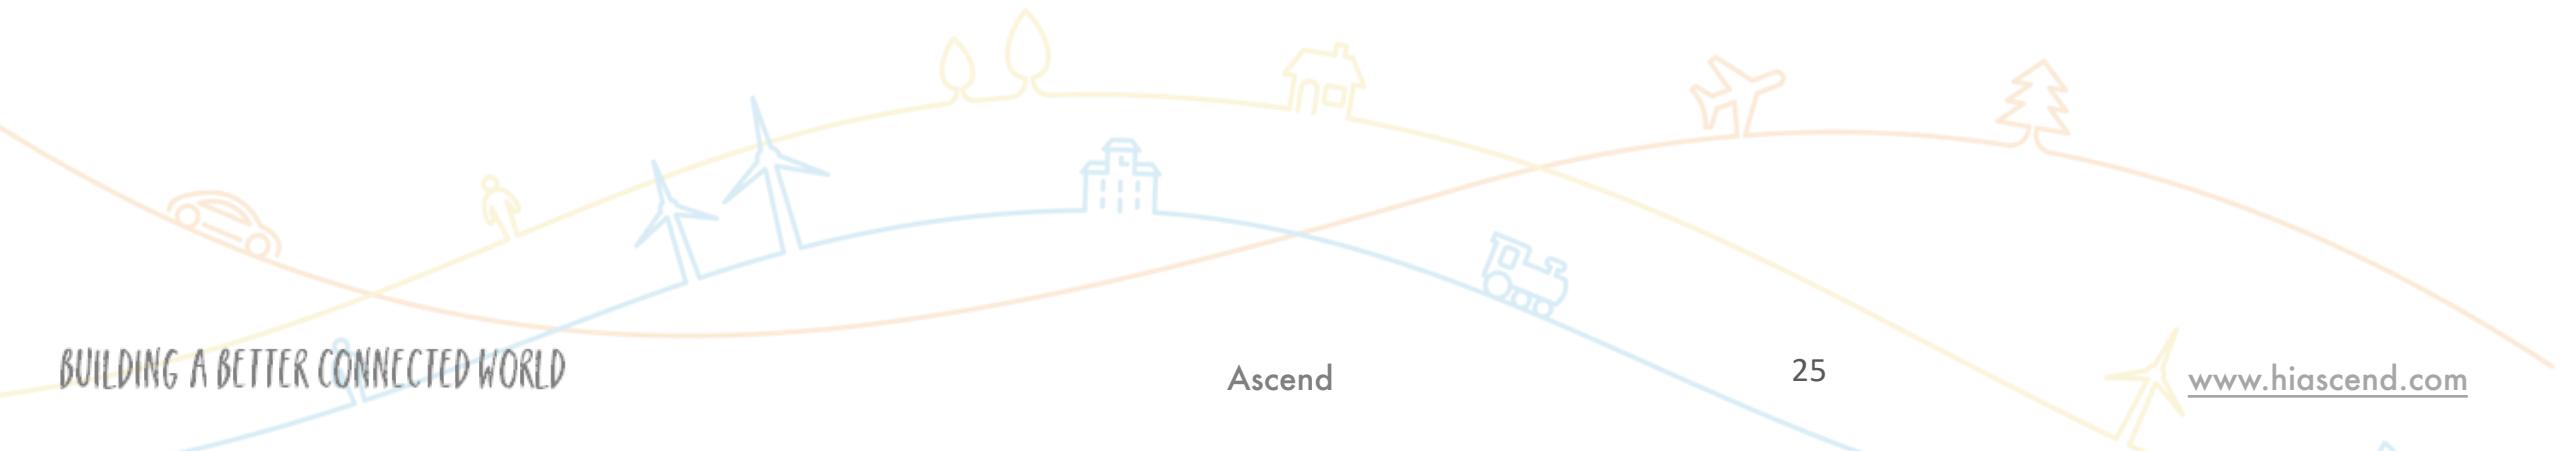
- 支持多种运算符（逻辑、加减等）和数据格式（FP16/BF16）
- SHARP控制器可以并行管理多达128个SHARP组
- XBAR的带宽调整到能够跟匹配SHA RP相关的数据传输

新NVLink模块

- 安全处理器保护数据和芯片
- 分区功能将端口隔离到NVLink网络
- 控制器支持下一代OSFP电缆



DGX 服务器



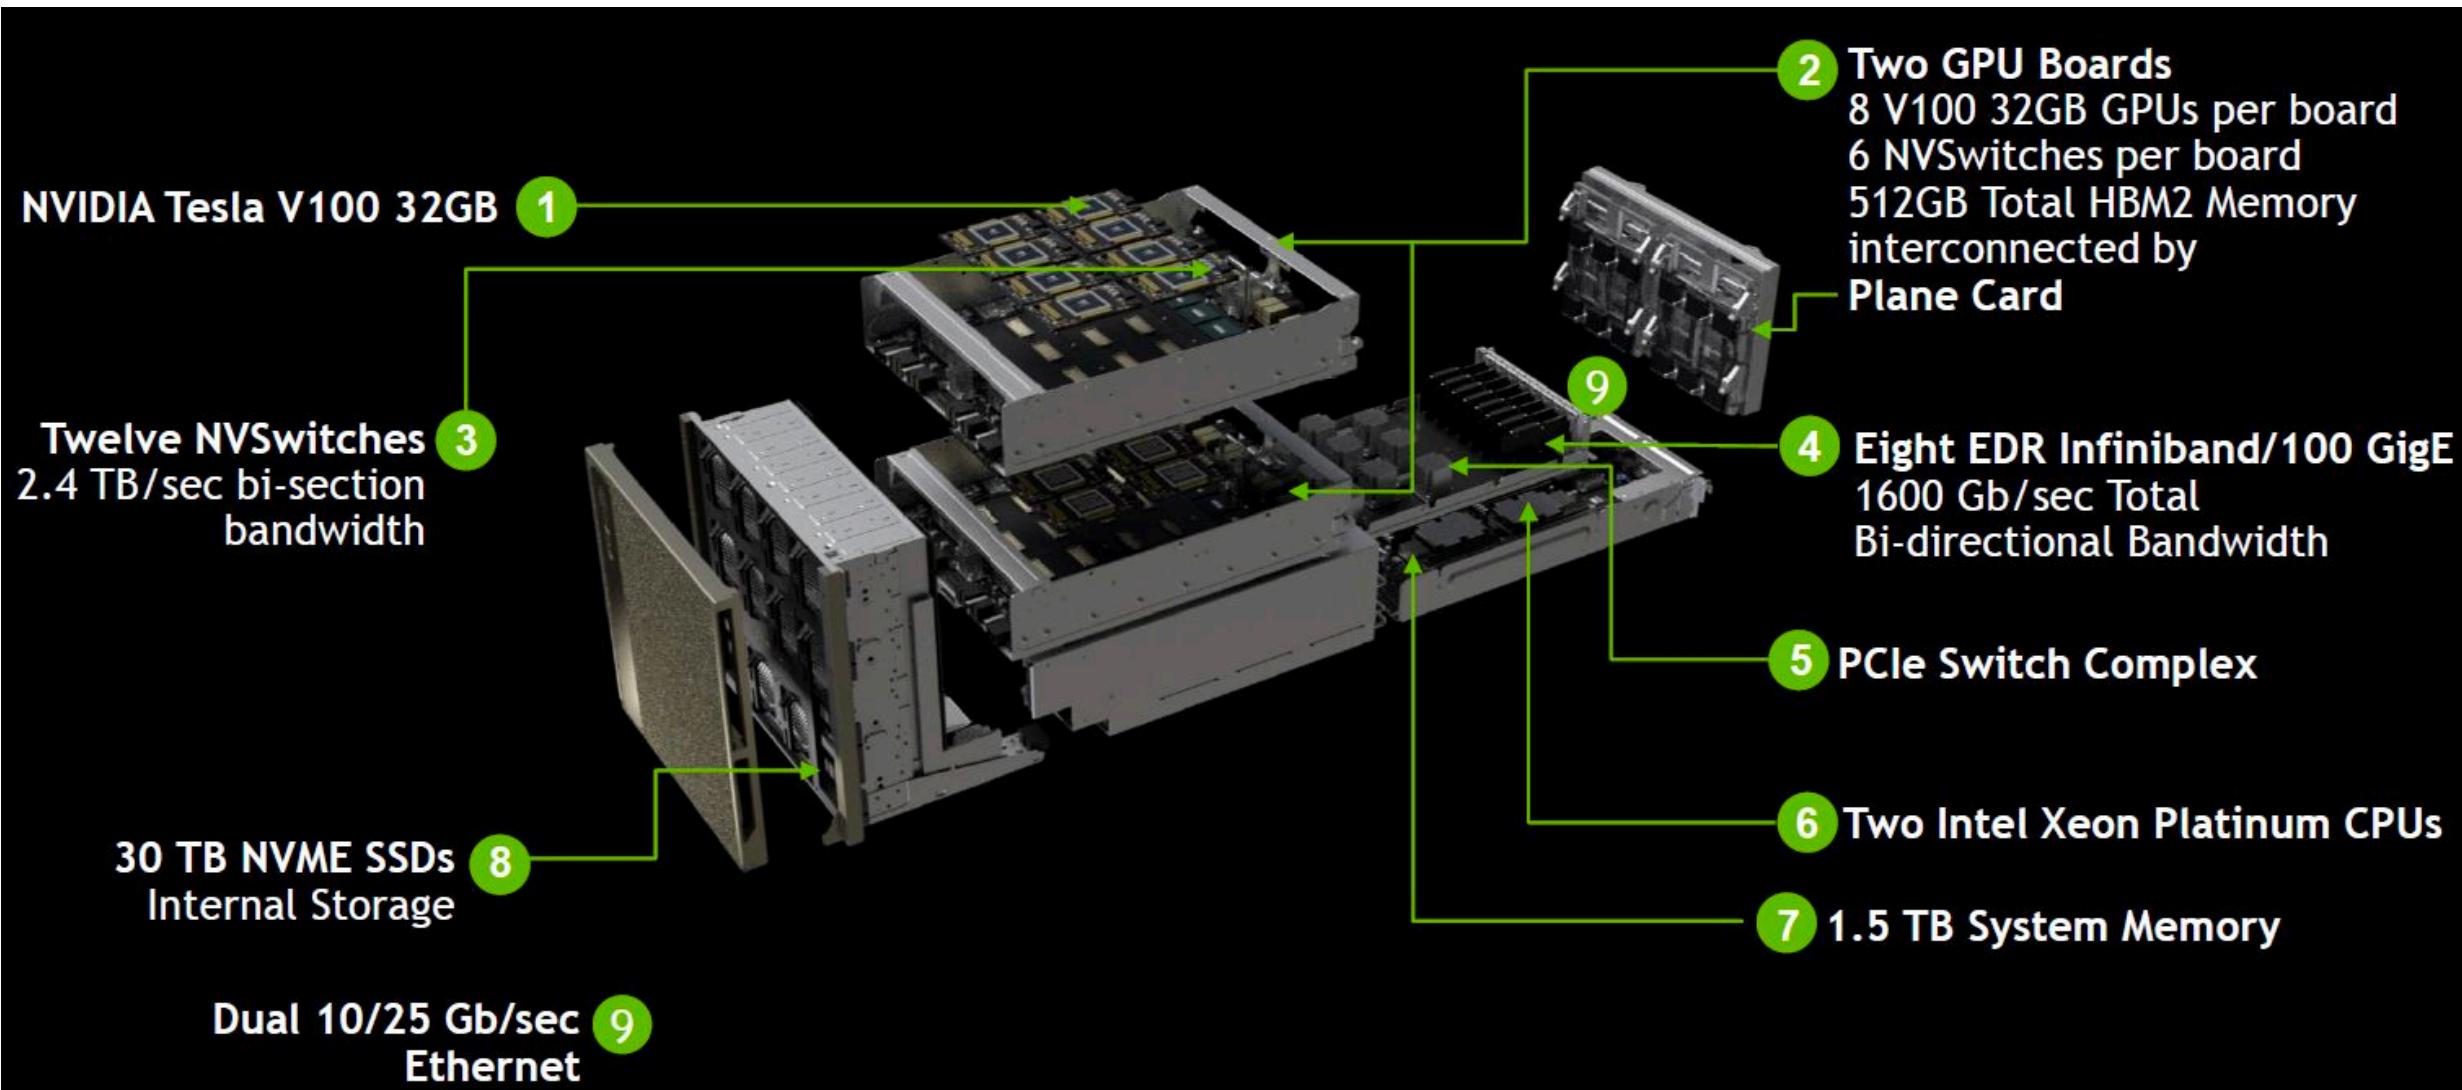
BUILDING A BETTER CONNECTED WORLD

Ascend

25



www.hiascend.com



Reference 引用&参考

1. <https://fuse.wikichip.org/news/1224/a-look-at-nvidias-nvlink-interconnect-and-the-nvswitch/>
2. <https://blog.csdn.net/BtB5e6Nsulg511Eg5XEg/article/details/86762135>
3. <https://developer.nvidia.com/blog/upgrading-multi-gpu-interconnectivity-with-the-third-generation-nvidia-nvswitch/>
4. <https://www.nextplatform.com/2016/05/04/nvlink-takes-gpu-acceleration-next-level/>
5. <https://www.servethehome.com/nvidia-nvlink4-nvswitch-at-hot-chips-34/>
6. <https://www.servethehome.com/nvidia-nvswitch-details-at-hot-chips-30/>
<https://hc34.hotchips.org/>
7. https://www.infoq.cn/article/3d4msrvs8zotgcj7*krt
8. <https://zhuanlan.zhihu.com/p/399405214>
9. <https://www.zhihu.com/question/63219175>
10. <https://developer.aliyun.com/article/591403>
11. <https://developer.aliyun.com/article/603617>
12. <https://developer.aliyun.com/article/599183>
13. https://blog.csdn.net/tony_vip/article/details/117131380



BUILDING A BETTER CONNECTED WORLD

THANK YOU

Copyright©2014 Huawei Technologies Co., Ltd. All Rights Reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.