

AI芯片思考



ZOMI



Talk Overview

I. AI 计算体系

- 深度学习计算模式
- 计算体系与矩阵运算

2. AI 芯片基础

- 通用处理器 CPU
- 通用图形处理器 GPU
- AI专用处理器 NPU/TPU

3. GPU详解

- 英伟达GPU架构发展
- Tensor Core和NVLink

4. 国外 AI 芯片

- 特斯拉 DOJO 系列
- 谷歌 TPU 系列

5. 国内 AI 芯片

- 壁仞科技芯片架构
- 寒武纪科技芯片架构

6. AI芯片的思考

- SIMD&SIMT与编程体系
- AI芯片的架构思路与思考


Talk Overview

I. AI 芯片思考

- thought 1 : 模型 Memory & FLOPs 增长
- thought 2 : 模型快速演变
- thought 3 : 生产部署需要多租户技术 Multi-tenancy
- thought 4 : 较大的 SRAM 和存取速度极快的 DRAM
- thought 5 : 重要的是内存 , 而非 FLOPs
- thought 6 : DSA 既要专业也要灵活
- thought 7 : 半导体技术发展速度不不同 , 要做好选型
- thought 8 : 编译器优化和 AI 应用兼容


thought 1 : 模型 Memory & FLOPs 增长

- 推理模型所需的内存空间和算力平均每年增长50%，模型所需内存和算力增长大约10~20倍
- 芯片设计1 years，部署1 years，实际使用并优化~3years，共5年




thought 1 : 模型 Memory & FLOPs 增长


1. 训练模型的增长速度比推理模型更快;
2. 2016-2023年，SOTA训练模型的算力需求年均增长10X；
3. GPT-2 模型的参数量从15亿增长到 GPT-3 1750亿，提高了100X。



thought 1 : 模型 Memory & FLOPs 增长



- A100 HBM 40G/80G
- HI00 HBM 64GB/94GB/ 188GB



• TPUv4 32G



• Ascend 64G



• DOJO 16G



• MLU 370 16G

thought 2 : 模型快速演变

- 深度学习是一个日新月异的领域
- 2015 年 MLP 仍为主流
- 2018 年 CNN、RNN 和 BERT 百花齐放
- 2020 年 Transformer 大模型独占鳌头
- DSA 需要足够通用支持新的模型

DNN Name	2020	2016
MLP0	25%	61%
MLP1		
CNN0	18%	5%
CNN1		
LSTM0	0%	29%
LSTM1		
RNN0	29%	0%
RNN1		
BERT0	28%	0%
BERT1		
TOTAL	100%	95%

thought 3 : 生产部署需要多租户技术 Multi-tenancy


- 大部分AI 相关论文假设同一时间 NPU 只需运行一个模型。实际应用需要切换不同模型：
 - 机器翻译涉及语言对，用不同的模型；
 - 用到一个主模型和配套多个实验进行模型；
 - 对吞吐量和延迟有不同要求，不同模型使用不用 batch size。

算力切分、显存虚拟化、内存寻址、虚拟内存页等技术~

thought 4 : 较大的 SRAM 和存取速度极快的 DRAM


- 较大的 SRAM 和存取速度极快的DRAM：
 - 红色虚线单芯片最大 SRAM，不少模型需要的内存远大于此。
 - 部分芯片设计思路 (Data-flow) 是期望利用 SRAM 解决所有任务。

	Multi-tenancy?	Avg # Programs (StdDev), Range
MLP0	Yes	27 (± 17), 1-93
MLP1	Yes	5 (± 0.3), 1-5
CNN0	No	1
CNN1	Yes	6 (10), 1-34
RNN0	Yes	13 (± 3), 1-29
RNN1	No	1
BERT0	Yes	9 (± 2), 1-14
BERT1	Yes	5 (± 0.3), 1-5




thought 5：重要的是内存，而非 FLOPs


1. 现代微处理器最大的瓶颈是能耗，而不是芯片集成度：
 - 访问 DRAM 能耗是访问片上 SRAM 100X；
 - 算术运算能耗的 5000 ~ 10,000X；
2. AI 芯片通过增加浮点运算单元（FPU）来分摊内存访问开销。
3. AI 系统开发者常通过减少浮点运算数 FLOPs 来优化模型，减少内存访问数是更有效的办法。



第三代 Tensor Core (Ampere)



第三代 Tensor Core (Ampere)




- Ampere 架构的 Tensor Core 一个 warp 中 32 个线程间共享数据，而 Volta 架构 Tensor Core 只有 8 个线程；
- 可以更好地在线程间减少矩阵的数据搬运。

Data-Flow 的硬件架构方式

- TPU v1 有 65,000 个乘法单元 (256×256)
- 700 MHz 时钟频率
- 峰值算力 : 92T Operations/s
 - $65,000 \times 2 \times 700M \approx 90$ TeraOPS
- 4 MB on-chip Accumulator memory
- 24 MB on-chip Activation Storage
- 2133MHz DDR3 DRAM channels for weights(8GB)

TPUv1: High-level Chip




脉动阵列 systolic array

- TPU 使用脉动阵列，以固定时间间隔使数据从不同方向流入阵列中的处理单元，最后将数据累积，以完成大型矩阵乘法运算。
- 70年代芯片只有单金属层，不能很好地实现互连，Kung和Leiserson提出“脉动阵列”以减少布线，简化连接。
- 现代芯片多达10个金属层，最大难点是能耗，脉动阵列能效高，使用脉动阵列可以使芯片容纳更多乘法单元，从而分摊内存访问开销。

Slides from
Shaaban

Systolic Architectures

- Replace single processor with an array of regular processing elements
- Orchestrate data flow for high throughput with less memory access



- Different from pipelining
 - Nonlinear array structure, multidirection data flow, each PE may have (small) local instruction and data memory
- Different from SIMD: each PE may do something different
- Initial motivation: VLSI enables inexpensive special-purpose chips
- Represent algorithms directly by chips connected in regular pattern

EECC756 - Shaaban

#1 lec # 1 Spring 2003 3-11-2003

thought 6 : DSA 既要专业也要灵活

- **DSA难点**：DSA 难点在于既要进行针对性的优化，同时还须保持一定的灵活性。
- **训练难点**：训练之所以比推理更加复杂，是因为训练的计算量更大，包含反向传播、转置和求导等运算。训练时需要将大量运算结果储存起来用于反向传播的计算，因此也需要更大的内存空间。
- **AI芯片需求**：计算的数据格式动态范围支持广泛（如BF16、FPI6、HF32），用于AI计算。指令、流水、可编程性也更高，需要灵活的编译器和上层软硬件配套。

thought 7：半导体技术发展速度不同，要做好选型

- 计算逻辑的进步速度很快，芯片布线的发展速度则较慢；
- 而 SRAM 和 HBM 比 DDR4 和 GDDR6 速度更快，能效更高。


Operation		Picojoules per Operation		
		45 nm	7 nm	45 / 7
+	Int 8	0.03	0.007	4.3
	Int 32	0.1	0.03	3.3
	BFloat 16	--	0.11	--
	IEEE FP 16	0.4	0.16	2.5
	IEEE FP 32	0.9	0.38	2.4
×	Int 8	0.2	0.07	2.9
	Int 32	3.1	1.48	2.1
	BFloat 16	--	0.21	--
	IEEE FP 16	1.1	0.34	3.2
	IEEE FP 32	3.7	1.31	2.8
SRAM	8 KB SRAM	10	7.5	1.3
	32 KB SRAM	20	8.5	2.4
	1 MB SRAM	100 ¹	14 ¹	7.1
GeoMean		--	--	2.6 ¹
DRAM		Circa 45 nm	Circa 7 nm	
	DDR3/4	1300	1300 ²	1.0
	HBM2	--	250-450 ²	--
	GDDR6	--	350-480 ²	--

Horowitz 1MB SRAM value is based on a single bank SRAM. Most engineers would use multiple banks, which is reason for 7.1x reduction in 1MB SRAM vs 2.4 for 32 KB SRAM.

1300 pJ for DDR3/4 DRAM is only the I/O [Sto12]. HBM2 and GDDR6 also list only the I/O energy [Mic17, O'C17, Smi20].

Horowitz M. "Computing's energy problem (and what we can do about it)". IEEE International Solid-State Circuits Conference Digest of Technical Papers, 2014.

Jouppi et al., Ten Lessons From Three Generations Shaped Google's TPUv4i, ISCA, 2021




thought 8：编译器优化和 AI 应用兼容

1. DSA 的编译器需要对AI 模型进行分析和优化，具体可分为与机器无关高级操作和与相关低级操作，从而提供，提供不同维度的优化 API 和 PASS。
2. 编译器维度目前比较多，有类似于 CUDA 提供编程体系，有类似于 TVM/XLA 提供编译优化：
 - 处理如 4096 个芯片的多核并行；
 - 向量、矩阵、张量等功能单元的数据级并行；
 - 322~400 位 VLIW 指令集的指令级并行；
 - 取决于软硬件能否进行缓存，编译器需要管理内存传输；
 - 编译器能够兼容不同功能单元和内存中的数据布局（如 Trans data）；


thought 8：编译器优化和 AI 应用兼容

- 与 CPU 和 NV GPU 相比，DSA 的软件栈还不够成熟。编译器优化最终能够提速多少？






thought 8：编译器优化和 AI 应用兼容

- 蓝色表示使用GPU，红色表示使用TPU，通过编译器优化后模型的性能提升到2X~。对C++编译器，能在一年内把性能提升5%-10%已经很厉害。



thought 8：编译器优化和 AI 应用兼容

- 一种重新排序注意力计算的算法，Flash Attention 并没有减少计算量 FLOPs，而是从 IO 感知出发，减少 HBM 访问次数，从而减少了计算时间。



Give your idea

- 你还有什么建议吗？





Thank you

把AI系统带入每个开发者、每个家庭、
每个组织，构建万物互联的智能世界

Bring AI System to every person, home and
organization for a fully connected,
intelligent world.

Copyright © 2023 XXX Technologies Co., Ltd.
All Rights Reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. XXX may change the information at any time without notice.



Course chenzomi12.github.io

GitHub github.com/chenzomi12/DeepLearningSystem